



Netflix Data Engineering & SQL Analytics Project

Este proyecto implementa una solución completa de ingeniería de datos utilizando **MySQL**, **Python** (**ETL**) y análisis exploratorio para comprender mejor el catálogo de Netflix. Incluye limpieza, normalización, modelado relacional, integración con datos externos (IMDb) y creación de consultas y visualizaciones analíticas.



Objetivos del Proyecto

1. **Construir una base de datos relacional** a partir del dataset público *Netflix Titles*.
2. **Normalizar datos clave**, especialmente géneros y reparto (cast).
3. **Integrar una segunda fuente de datos** (IMDb) para enriquecer la información.
4. **Crear consultas SQL** que respondan preguntas analíticas reales.
5. **Generar visualizaciones e insights** desde un Jupyter Notebook.
6. **Diseñar un modelo entidad-relación (ERD)** profesional.
7. **Producir scripts** `.sql` **completos** reproducibles por cualquier usuario.



Estructura del Proyecto

```
project/
├── data/
│   └── normalized/
│       ├── netflix_titles_clean.csv
│       ├── genres.csv
│       ├── title_genres.csv
│       ├── actors.csv
│       ├── title_actors_raw.csv
│       ├── title_actors.csv (opcional)
│       ├── imdb_movies_clean.csv
│       ├── netflix_imdb_map.csv
│       ├── inserts.sql
│       ├── inserts_actors.sql
│       └── inserts_imdb.sql
├── etl/
│   ├── generate_inserts.py
│   ├── split_actors_minimal.py
│   ├── clean_netflix_data.py
│   └── imdb_matching.py
└── sql/
```

```
| | reset_create_load_all_mysql.sql
| | create_tables.sql
| | load_data.sql
| | queries_analysis.sql
|
| notebooks/
| | netflix_analysis.ipynb
|
| README.md (este archivo)
```

Descripción de las Tablas

1. netflix_titles (tabla principal)

Contiene toda la información original del catálogo de Netflix.

Columna	Descripción
show_id (PK)	ID del título
type	Movie / TV Show
title	Título
director	Director(es)
cast	Lista original de actores
country	País de producción
date_added	Fecha de ingreso al catálogo
release_year	Año de lanzamiento
rating	Clasificación por edad
duration_raw	Duración original
duration_int	Duración numérica
duration_unit	Unidad (min, Seasons)
description	Sinopsis

2. genres

Catálogo único de géneros.

Columna	Descripción
genre_id (PK)	ID del género
genre_name	Nombre del género

3. title_genres (tabla puente)

Relaciona títulos con géneros (relación N:N).

Columna	Descripción
show_id (FK)	Título
genre_id (FK)	Género

4. actors

Catálogo único de actores.

Columna	Descripción
actor_id (PK)	ID del actor
actor_name	Nombre del actor

5. title_actors (tabla puente)

Relaciona títulos con actores (relación N:N).

Columna	Descripción
show_id (FK)	Título
actor_id (FK)	Actor

6. imdb_movies

Datos enriquecidos provenientes de IMDb.

Columna	Descripción
imdb_id (PK)	ID IMDb
title	Título IMDb

Columna	Descripción
original_title	Título original
year	Año
imdb_rating	Rating IMDb
imdb_votes	Número de votos
runtime	Duración (min)
genres	Lista IMDb
directors	Directores
countries	Países

7. netflix_imdb_map

Relación entre títulos de Netflix y su equivalente en IMDb mediante fuzzy matching.

Columna	Descripción
show_id (FK)	Netflix
imdb_id (FK)	IMDb
match_score	Score de similitud (0-100)

Modelo Entidad-Relación (ERD)

El diagrama completo se encuentra en el archivo:

✓ `netflix_full_erd.mmd` (formato Mermaid)

Puedes visualizarlo en: - <https://mermaid.live/> - VSCode con extensión Mermaid Preview

Scripts SQL Incluidos

1. reset_create_load_all_mysql.sql

Incluye: - DROP DATABASE - CREATE DATABASE - Todas las tablas - Llaves foráneas y constraints - LOAD DATA desde CSV

2. inserts.sql / inserts_actors.sql / inserts_imdb.sql

Scripts generados automáticamente por ETL para poblar la base de datos.

Flujo ETL

1. **Limpieza inicial** del dataset de Netflix.
2. **Normalización de géneros** → `genres.csv` + `title_genres.csv`.
3. **Extracción del reparto (cast)** → generación de:
4. `actors.csv`
5. `title_actors_raw.csv`
6. `title_actors.csv`
7. **Integración IMDb:**
8. limpieza del dataset IMDb
9. matching con RapidFuzz
10. `netflix_imdb_map.csv`
11. **Generación de scripts SQL** de carga.

Consultas de Ejemplo

1. Top 10 países con más títulos

```
SELECT country, COUNT(*) AS total
FROM netflix_titles
GROUP BY country
ORDER BY total DESC
LIMIT 10;
```

2. Actores con más apariciones

```
SELECT a.actor_name, COUNT(*) AS appearances
FROM title_actors ta
JOIN actors a ON a.actor_id = ta.actor_id
GROUP BY a.actor_name
ORDER BY appearances DESC
LIMIT 10;
```

3. Relación Netflix-IMDb (matching alto)

```
SELECT nt.title, im.imdb_rating, nm.match_score
FROM netflix_imdb_map nm
JOIN netflix_titles nt ON nt.show_id = nm.show_id
JOIN imdb_movies im ON im.imdb_id = nm.imdb_id
```

```
WHERE match_score >= 85  
ORDER BY imdb_rating DESC;
```



Notebook

El cuaderno `notebooks/netflix_analysis.ipynb` incluye: - Limpieza de datos final - Estadísticas descriptivas - Visualizaciones (Matplotlib/Seaborn/Plotly) - Insights clave



Requisitos

- Python 3.10+
 - MySQL 8+
 - Pandas
 - RapidFuzz (para matching)
 - Matplotlib / Seaborn / Plotly
-



Autor

Proyecto desarrollado por **Deysi Gálvez** como parte del programa Data Analytics en **Ironhack**.



Licencia

Uso académico y demostrativo. Puedes reutilizar la estructura para otros proyectos de análisis de datos.